

計算資源制約下における言語モデルの日本語ストーリー 文順序付け能力の評価

Evaluating Sentence Ordering in Japanese Narratives with Lightweight Language Models

横山明咲^{*1} ジェプカ ラファウ^{*2}
Asa Yokoyama Rafal Rzepka

^{*1}北海道大学 大学院情報科学院
Graduate School of Information Science and Technology, Hokkaido University

^{*2}北海道大学 大学院情報科学研究院
Faculty of Information Science and Technology, Hokkaido University

In recent years, the demand for local Large Language Models (LLMs) has surged, driven by privacy and security considerations. However, lightweight models with 7–8B parameters significantly underperform compared to cloud-based models in temporal reasoning tasks. This study addresses this performance gap based on the Japanese narrative dataset “DanSto.” First, we propose a reliable evaluation framework by eliminating data ambiguity through a voting ensemble of multiple GPT models. Second, to mitigate issues such as position bias, we employ a Supervised Fine-Tuning (SFT) strategy that simplifies model outputs into alphabet-labeled lists. Experimental results demonstrate that Qwen3-8B outperforms other models of a similar size and achieves accuracy levels approaching those of GPT-4o. Our findings suggest that reducing the generation load by allowing the model to focus on symbolic manipulation is particularly effective for enhancing reasoning performance.

1. はじめに

近年、大規模言語モデル（LLM）の社会実装が急速に進展している。GPT-4 に代表されるクラウド型 LLM が高い汎用性能を示す一方で、プライバシー保護や運用コスト、通信遅延の観点から、ユーザのローカル環境で動作する「ローカル型 LLM（7B-8B パラメータ程度）」への需要が高まっている。しかし、これらの小規模モデルは、クラウド型と比較して複雑な文脈理解や論理推論能力において著しく性能が劣るという課題がある [Wei 22]。特に、テキスト内の出来事の因果関係や時間的順序を復元する「文順序付け（sentence ordering）」タスクは、モデルが文脈を深く理解しているかを測る重要な指標であるが、既存モデルはこのタスクにおいて順序バイアス（position bias）の影響を受けやすく、正確な推論が困難である。

また、このタスクの評価における本質的な課題として、データセットに含まれる「解釈の曖昧性」が挙げられる。既存の物語データセットには、複数の順序が成立しうるデータが含まれており、これがモデルの純粋な推論能力の測定を妨げている。

そこで本研究では、日本語物語データセット「DanSto」 [Rzepka 24] を用い、ローカル型 LLM の文順序付け能力を向上させるための包括的なアプローチを提案する。本研究の貢献は以下の 3 点である。

第一に、評価の信頼性を担保するため、高性能 LLM（GPT-4o 等）の投票アンサンブルを用いたデータ選別手法を提案する。これにより、解釈が一意に定まる「良問（Easy データセット）」のみを抽出し、客観的な評価基盤を構築した。

第二に、推論過程（reasoning process）を明示的に学習させる SFT 手法を導入した。従来の SFT では「指示（instruction）」と「入力（input）」に対し「回答（output）」のみを学習させていたが、本手法では出力の冒頭に <think> タグを設け、Teacher モ

デルが生成した論理的な導出過程を組み込む。この際、Teacher モデルとして高性能な GPT-4o を用いる手法に加え、Qwen3-8B 自身が持つ推論機能により生成した思考プロセスを用いる手法についても比較検証を行う。

第三に、上記手法におけるデータ量のスケーリング効果を検証した。学習データ数 1,000 件から 2,000 件、5,000 件へと拡張し、ローカル型 LLM における「推論プロセスの質」と「学習データ量」が推論精度に与える相関関係を明らかにする。

2. 関連研究

文順序付けタスクへのアプローチ

文順序付け（sentence ordering）は、テキストの一貫性や論理構造の理解を評価する重要なタスクである。従来は、BERT などの事前学習済みモデルにポインタネットワーク等のタスク専用のアーキテクチャを付加した特化型モデル（discriminative models）が主流であり、文ペアの関係性を学習することで高い精度を達成してきた [Shi 24]。しかし、これらの研究はモデル構造そのものが特定のタスクに依存しており、汎用的な推論プロセスを抽出・活用する上での制約となっていた。

LLM と In-Context Learning

近年では、大規模言語モデル（LLM）の登場により、In-Context Learning (ICL) や Instruction Tuning を用いた生成アプローチが注目されている。LLM は、大量のテキストデータから学習した知識に基づき、明示的な学習なしにタスクを遂行する能力を持つ。しかし、[Qiu 24] らは、GPT-4 を含む最先端の LLM であっても、文順序付けのような厳密な時間的推論においては、特化型モデルに劣る場合があることを報告している。

生成と推論の競合

LLM を論理推論タスクに適用する際の課題として、[Mahowald 24] らは「形式的言語能力（流暢な文章生成）」と「機能的言語能力（論理推論）」の乖離を指摘している。特に計算資源が限られた小規模なローカルモデルにおいては、長文生成に伴う負荷が論理推論のリソースを圧迫する「タスク干

連絡先: 横山明咲, 北海道大学 大学院情報科学院, 札幌市北区北 14 条西 9 丁目, 011-706-7389, yokoyama.asa.q1@elms.hokudai.ac.jp

表 1 LLM 投票アンサンブルによるデータ分類基準

分類	定義 (3 モデルの回答状況)	採用
Easy	全員が正解 (Correct, Correct, Correct)	○
Medium	多数決で正解 (Correct, Correct, Incorrect)	×
Ambiguous	全員または一部が同じ誤答 (別解の可能性)	×
Hard	不正解が分散	×
Very Hard	全員が異なる間違い	×

渉 (task interference)」が生じやすい。このため、本研究では [Basu Roy Chowdhury 21] らの Text-to-Marker 手法を参考に、出力を記号列 (リスト形式) に単純化することで、推論能力を最大限に引き出すアプローチを採用する。

3. 評価基盤の構築

3.1 日本語物語データセット「DanSto」

本研究では、評価用データセットとして日本語物語データセット「DanSto」[Rzepka 24]を採用する。DanSto は、クラウドソーシングによって作成された全 8,757 件の物語 (各 5 文構成) からなる。本データセットを採用する最大の利点は、Web 上に一般公開されていないため^{*1}、LLM の事前学習データに含まれている可能性が低い (データ汚染がない) 点にある。これにより、モデルが単なる知識の記憶 (暗記) ではなく、未知の文脈に対して自律的に推論を行っているかを厳密に測定することが可能となる。

3.2 LLM 投票アンサンブルによる難易度ラベリング

文順序付けタスクにおける最大の課題は、データセット内に「複数の順序が成立しうる物語 (解釈の曖昧性)」が含まれている点である。実際、筆者による予備実験において、BERT 等の特化型モデルや単純なプロンプトエンジニアリングでは精度改善に限界が見られ、その要因として「正解が一意に定まらないデータ」がモデルの正確な評価を妨げていることを確認した。

そこで本研究では、この曖昧さを排除し、客観的に正解が一意に定まる信頼性の高い評価基盤を構築するため、高性能 LLM を用いた投票アンサンブルによるデータ選別手法を提案する。具体的には、高い推論能力を持つ 3 つのモデル (GPT-4o, GPT-4-turbo, GPT-5) に対し、DanSto のテストセット (464 件) の並び替えを行わせ、その回答の一致状況に基づいて表 1 のように難易度を定義した。

本手法により、3 モデル全てが正解データと完全に一致した順序を出力した場合のみを「Easy データ (良問)」として抽出した。この選別の結果、元のテストセット 464 件のうち、曖昧性がなく論理的に解が一意に定まると判断された 219 件 (約 47%) を、本研究における評価用データセットとして採用する。

4. 提案手法

本章では、ローカル型 LLM の文順序付け能力を最大化するための手法について述べる。本手法は、(1) モデルの入力・出力形式の最適化によるバイアスの低減と、(2) 教師ありファインチューニング (SFT) におけるデータスケーリングの拡張および推論過程 (reasoning process) の蒸留の 2 段階から構成される。

4.1 入出力形式の最適化

予備実験において、7B クラスのローカルモデルは、指示そのものよりも「数値の並び」や「長文生成」といった形式的な制約

に強く影響を受けることを確認した。そこで本研究では以下の 2 点の最適化を行う。

1. アルファベットラベル化による数値バイアスの回避

文の識別子として数値 (0, 1, 2...) を用いた場合、モデルが文脈の内容ではなく、few-shot (例示) で提示された回答の「数値の並び」そのものを機械的に模倣してしまう「例示過学習バイアス」が支配的になることが予備実験により確認された。これは、数値ラベルが持つ強い順序性が、モデルの注意を「内容の推論」から「表面的な数字のコピー」へと逸らしてしまうためである。そこで本手法では、順序性の意味合いが薄いアルファベット (A, B, C...) を採用し、プロンプト内で「ラベルは順序と無関係である」ことを明示する。筆者らの先行調査では、この変更により 7B パラメータ級の複数のモデルを用いた予備実験において、同バイアスの発生率を約 70% から 2% 程度まで低減できることが確認されている。

2. List 形式による評価の安定化と負荷低減

物語全文を再生成する Sentence 形式では、モデルの推論自体が正しくても、出力時に微細な誤字脱字や句読点の差異、あるいは表記ゆれが生じるだけで、正解データとの完全一致判定が困難になるという評価上の課題がある。

そこで本研究では、回答としてラベルの順序を示すリスト (例: ["B", "D", "A", "C", "E"]) のみを出力させる「List 形式」を採用する。これにより、評価の不確実性を排除するとともに、前述したタスク干渉を回避し、モデルの計算リソースを純粋な順序決定の論理推論に集中させる。

4.2 教師ありファインチューニングの拡張

従来の SFT は「指示 (instruction)」と「入力 (input)」に対し「出力 (output)」のみを対学習させる形式が一般的であったが、この手法では複雑な文脈理解を要するタスクにおいて推論の深化が不十分となり、完全一致率 (PMR) が停滞する課題があった。本研究では、SFT の「量」と「質」の双方を拡張することで、この課題の解決を図る。

1. 出力形式のバリエーション

モデルの出力形式が推論精度に与える影響を検証するため、同一の入力に対して異なる 2 種類の出力形式を持つデータセットを作成した。

- **List 形式:** 正しい順序のアルファベット記号のみをリスト形式で出力する。
- **Sentence 形式:** ラベルに続けて物語全体を再構成して出力する。

2. データスケーリングの検証

まず、学習データ量と推論精度の関係を検証するため、学習データのサイズを拡張する。本実験では DanSto の学習用プール (約 8,000 件) からランダムに抽出した 1,000 件、2,000 件、5,000 件の 3 水準のデータセットを作成した。これにより、ローカル LLM における「純粋なデータ量」が文順序付けタスクの精度に与える影響のベースラインを測定する。なお、各データセットは包含関係 (1,000 件 ⊂ 2,000 件 ⊂ 5,000 件) にある。

この段階での学習データ (以下、Standard SFT) の構成は、評価時の比較を容易にするため、空の <think> タグを設けた以下の形式とした。

```
{"instruction": "[タスク指示]",
  "input": "[5 つの文セット]",
  "output": "<think>\n</think>
  [answer (List 形式 or Sentence 形式)]"}
```

3. 推論過程の蒸留

次に、学習データに明示的な「思考プロセス」を組み込むこと

^{*1} 入手には著者への利用申請が必要であり (available on request)、インターネット上に一般公開されているものではない。

で、モデルの推論能力を直接的に強化する手法を導入する。具体的には、Teacher モデルとして高い推論性能を有する GPT-5、および推論機能を有効化したベースモデル (Qwen3-8B) を用い、正解に至った試行から得られた高品質な推論過程を抽出した。学習データは <think> タグ内にこれらの思考過程を格納し、その後正解順序を連結した形式とする。本手法により、モデルに対して「回答前に論理を整理するステップ」を学習させ、論理的整合性の向上を狙う。

推論過程を含む学習データ (以下、Think SFT) の構成は以下の通りである。

```
{ "instruction": "[タスク指示]",
  "input": "[5つの文セット]",
  "output": "<think>[reasoning process]</think>
            [answer (List 形式 or Sentence 形式)]" }
```

5. 実験

5.1 実験設定

本実験では、提案手法 (データスケーリングおよび思考過程学習) の有効性を検証するため、以下の設定で評価を行った。

評価モデル

比較対象として 7B モデルの Qwen2.5-7B、参照モデルとして GPT-4o [OpenAI 24] を用いた。ベースモデルには、Qwen3-8B を採用した。これに対し、提案手法である「アルファベットリスト形式」での SFT (instruction tuning) を適用したモデルと比較を行う。

評価データ

第 3 章で構築した「Easy データセット (219 件)」からランダムに抽出した 100 件を評価用データとして使用した。

評価指標

モデルの出力精度を多角的に測るため、以下の 3 つの指標を用いた。

- 完全一致率 (PMR): 出力された順序が正解と完全に一致した割合。最も厳格な指標である。
- Kendall's τ : 順序の相関係数 (-1.0~1.0)。全体的な傾向の正しさを測る。
- 位置正答率 (Positional Accuracy): 各文が正しい位置に配置された割合。

5.2 結果 1: スケーリングと出力形式の効果

本節では、出力形式 (List 形式 vs Sentence 形式) および学習データ量 (1,000 件, 2,000 件, 5,000 件) が推論精度に与える影響を検証する。ここでは、比較のため推論過程を含まない「Standard SFT」の結果に基づき分析を行う。

図 1 は、データ量に応じた各手法の PMR 推移を既存モデルのスコアと共に示したものである。図より、以下の 2 つの主要な知見が得られた。

第一に、出力形式の最適化によるスケーリング効率の劇的な向上である。すべてのデータサイズにおいて、List 形式は Sentence 形式を一貫して上回った。特筆すべきは、5,000 件の学習を行った Sentence 形式 (PMR 0.64) よりも、わずか 2,000 件の List 形式 (PMR 0.66) の方が高い精度を記録した点である。これは、小規模モデルにおいて物語全文を生成させる負荷 (タスク干渉) がいかに大きく、出力を記号列に限定する「形式の簡略化」がスケーリング効率を最大化する上で有効であることを示している。

第二に、データ量増加に伴う着実な精度の向上である。List 形式において、データ数を 1,000 件から 5,000 件へと拡張する




図 1 学習データ数に対する精度のスケーリング効果

表 2 思考過程の導入および Teacher モデルの違いによる性能評価 (Qwen3-8B, 1k データ, List 形式)

手法 (学習データ種別)	推論	PMR	Kendall's τ	PA
Base	ON	0.64	0.754	0.746
Standard SFT	OFF	0.58	0.848	0.782
SFT Qwen3-8B _{Think}	ON	0.52	0.588	0.628
SFT Qwen3-8B _{Think}	OFF	0.46	0.776	0.694
SFT GPT-5 _{Think}	ON	0.56	0.808	0.752
SFT GPT-5 _{Think}	OFF	0.47	0.812	0.722

につれ、PMR は 0.58 → 0.66 → 0.70 と向上し、5k 学習時点においても精度の飽和傾向は見られないことから、さらなるデータ拡充によって参照モデルである GPT-4o (0.93) へさらに接近できる可能性が示唆された。興味深いことに、学習データ 1,000 件時点での PMR (0.58) は、ベースモデルの推論 ON 時の性能 (0.64) を下回っている。これは、小規模なデータによる SFT だけでは、ベースモデルが元来備えている高度な推論能力を十分に代替・再現できていないことを示唆している。しかし、データサイズを 2k へと拡張した段階で PMR 0.66 を記録し、ベースラインを突破した。この事実は、ある一定のデータ量を境界として、特定の形式に特化させた学習による精度の積み上げが、ベースモデルの汎用的なゼロショット性能を凌駕する「性能の逆転地点 (crossover point)」が存在することを示している。

5.3 結果 2: 推論過程学習の有効性検証

次に、学習データに明示的な推論過程 (reasoning) を含めることの効果を検証する。前節の結果より、出力形式は「List 形式」が最も有効であることが示されたため、本節では List 形式を用いた各手法の比較を行う (表 2 参照)。

表 2 の結果から、推論過程の導入に関して、当初の予想とは異なる知見が得られた。

第一に、指標間の逆転現象と推論出力の不安定性である。思考過程を学習させたモデル群 (Think 系) においては、推論を ON にすることで PMR が向上する傾向 (例: GPT-5_{Think} では 0.47 → 0.56) が確認された。しかしその一方で、相関指標である Kendall's τ は推論 OFF 時の方が高い、あるいは ON にしても微増に留まるという挙動を示した。特に SFT Qwen3-8B_{Think} では、推論 ON によって PMR が向上した反面、 τ が 0.776 から 0.588 へと大幅に下落した。これは、小規模モデルにおいて思考ステップを出力させることが、特定の正解 (完全一致) を導くガイドとして機能する一方で、出力の長文化に伴う論理的破綻 (ハルシネーション) を招きやすく、物語全体の整合性を損なう「諸刃の剣」となっていることを示唆している。

第二に、学習データと推論設定の不一致によるノイズの発生である。Standard SFT モデルでは、推論 OFF (0.58) が推論 ON (0.56) を上回る精度を記録した。これは学習時に推論過程が含まれていなかったため、評価時に推論を強制することが Student モデルにとって未知の負荷 (ノイズ) となり、精度を低下させたと考えられる。一方で、Think 系モデルでは推論 ON が OFF を大きく上回ったことから、Student モデルが Teacher モデルの思考プロセスを学習し、それを活用して自身の判断を補正できていることは確認できた。しかし、その補正後の精度であっても、直接回答を学習した Standard SFT の精度には届いていない。

第三に、思考過程学習の根本的な非効率性である。高品質な GPT-5 の思考を蒸留した GPT-5^{Think} であっても、その最高精度は Standard SFT (PMR 0.58, τ 0.848) に及ばなかった。これは、7B-8B クラスのモデルにおいて、複雑な思考トレースを完全に模倣 (蒸留) するコストが、本来のタスク推論に割り当てるべきパラメタリソースを圧迫してしまう「蒸留の副作用」が発生している可能性を示している。

以上の分析から、本タスクのような文順序入れ替えにおいては、小規模モデルに対して「なぜその順序になるか」を説明させる能力を求めるよりも、リスト形式という簡略化されたインターフェースを通じて直接解を導出させる学習の方が、全体の安定性と正解率の両面において極めて効率的であると結論付けられる。

6. 考察

6.1 データスケールにおける性能の閾値

図 1 に示した通り、提案手法である Standard SFT はデータ量に伴い線形に近い精度向上を示したが、1,000 件時点ではベースモデルの推論 ON 設定 (0.64) を下回る結果となった。これは、ベースモデルが事前学習で獲得した汎用的な推論能力を、単一タスクの少規模な学習 (1,000 件) のみで代替することの困難さを示している。しかし、データ量を 2,000 件へと拡張した段階でベースラインを突破し、5,000 件では PMR 0.70 に到達した。この事実、特定の出力形式 (List 形式) への特化が、ある一定のデータ量 (本実験では 2,000 件付近) を境に、汎用モデルの推論ポテンシャルを実用的なレベルで凌駕する「性能の閾値」が存在することを示唆している。

6.2 蒸留の副作用と学生・教師間の能力ギャップ

本実験における最大の発見は、次世代最高峰モデルである GPT-5 の推論過程を蒸留した「Think SFT」が、直接回答を学習した「Standard SFT」に及ばなかった点である。これには、7B-8B クラスのモデルにおける「パラメタ容量の限界」が深く関与していると考えられる。GPT-5 が生成する高度で長大な論理トレースを模倣しようと試みる際、小規模モデルは限られたリソースを「論理の維持」と「正答の導出」に分散せざるを得ない。結果として、推論過程の出力が冗長化し、微細な論理的な一貫性の欠如が出力にノイズを混入させる「自己汚染」を引き起こしたと推察される。特に Kendall's τ の大幅な下落は、長大な推論が物語全体の構造理解をかえって攪乱したことを如実に示している。本タスクにおいては、説明能力の獲得と正解精度の向上は必ずしも相関せず、小規模モデルにおいては、冗長な思考プロセスの生成を避け、リスト形式のような簡略化された出力形式に特化させることが、限られたパラメタリソースを最適化する上で最も効率的な学習戦略であることが明らかになった。

7. おわりに

本研究では、7B-8B クラスのローカル型 LLM を対象に、文順序付けタスクにおける精度最大化の手法を検討した。実験の結果、アルファベットを用いた「List 形式」の採用と、5,000 件規模のデータスケールにより、既存の同規模モデルを大きく上回る PMR 0.70 を達成した。一方で、高性能な Teacher モデル (GPT-5) を用いた推論過程の蒸留は、1,000 件データ環境下において、直接的な回答学習 (Standard SFT) の精度を上回ることが困難であるという「蒸留の限界」を明らかにした。本知見は、高度な文脈理解と論理的な一貫性の把握が要求される難易度の高い文順序付けタスクにおいて、計算資源が限られた環境下でローカル型 LLM を実用レベルへ引き上げるための、実践的な指針となるものである。

今後の展望として、DPO 等の選好学習を用い、思考の「形式」ではなく「正解」に対して直接フィードバックを与えることで、蒸留の副作用を回避しつつ精度を向上させる手法の検討が必要である。また、提案した投票アンサンブルによる難易度ラベルの妥当性を検証するため、人手による評価を導入し、構築した評価基盤の信頼性をより強固なものにすることを目指す。

参考文献

- [Basu Roy Chowdhury 21] Basu Roy Chowdhury, S., Brahman, F., and Chaturvedi, S.: Is Everything in Order? A Simple Way to Order Sentences, in Moens, M.-F., Huang, X., Specia, L., and Yih, S. W.-t. eds., *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pp. 10769–10779, Online and Punta Cana, Dominican Republic (2021), Association for Computational Linguistics
- [Mahowald 24] Mahowald, K., Ivanova, A. A., Blank, I. A., Kanwisher, N., Tenenbaum, J. B., and Fedorenko, E.: Dissociating language and thought in large language models, *Trends in cognitive sciences*, Vol. 28, No. 6, pp. 517–540 (2024)
- [OpenAI 24] OpenAI, : GPT-4 Technical Report (2024)
- [Qiu 24] Qiu, Y., Zhao, Z., Ziser, Y., Korhonen, A., Ponti, E., and Cohen, S.: Are Large Language Model Temporally Grounded?, in *NAACL 2024*, pp. 7064–7083, Mexico City, Mexico (2024), Association for Computational Linguistics
- [Rzepka 24] Rzepka, R., Dudzic, K., Abe, A., and Araki, K.: DanSto - Japanese dataset of short stories for evaluating context understanding, 人工知能学会第二種研究会資料, Vol. 2023, No. AGI-026, pp. 32–40 (2024)
- [Shi 24] Shi, Y., Zhang, H., Li, N., and Yang, T.: An overview of sentence ordering task, *International Journal of Data Science and Analytics*, Vol. 18, No. 1, pp. 1–18 (2024)
- [Wei 22] Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., Chi, E. H., Hashimoto, T., Vinyals, O., Liang, P., Dean, J., and Fedus, W.: Emergent Abilities of Large Language Models, *Transactions on Machine Learning Research* (2022), Survey Certification