

計算資源制約下における言語モデルの
日本語ストーリー文順序付け能力の評価

横山 明咲 *1

*1北海道大学 大学院情報科学院

ジェプカ・ラファウ *2

*2北海道大学 大学院情報科学研究院



研究背景

LLMの実社会応用(ロボット、自律エージェント)において、
出来事の順序を理解する「文順序付け」は不可欠 [1]

目的

高度な文脈理解を要する文順序付けにおいて、小規模LLMの推論限界の突破を検証し、GPT-4に迫る精度を目指す

評価タスク

シャッフルした5つの文を正しい物語順に並び替える単語の共起だけでなく、
文脈理解が必要

評価データ

DanSto [2] : 5文からなる日本語の短いストーリー

- 例) 0) 朝ご飯は家族みんなで食べる。
1) 朝ご飯はみんなで準備をする。
2) 私はトーストにバターを塗っていた。
3) 親が冷蔵庫から牛乳を持ってきた。
4) 私はコップに牛乳を注いだ。

データ内に解釈の
曖昧性の存在？

評価基盤

各物語データに対して難易度に関するラベル付けを行った

表 1 LLM 投票アンサンブルによるデータ分類基準

分類	定義 (3 モデルの回答状況)	採用
Easy	全員が正解 (Correct, Correct, Correct)	○
Medium	多数決で正解 (Correct, Correct, Incorrect)	×
Ambiguous	全員または一部が同じ誤答 (別解の可能性)	×
Hard	不正解が分散	×
Very Hard	全員が異なる間違い	×

- 例) 0) 親子で川釣りに出かける。
1) 数匹の魚を釣ることができた。
2) 父親が火を起こし魚を焼く準備をする。
3) 釣った魚を串に刺し火の周りに並べる。
4) 親子で焼いた魚を食べた。

解釈が一意に定まるデータ
のみを用いて評価を行う

入出力形式の最適化

全文再生成ではなくラベルを用いたリスト形式を用いた

① 位置バイアスの回避

Bad

数値ラベル(0,1,2...)
→入力順・例示順での出力多数

バイアス発生率:70%

Good

アルファベットラベル(A,B,C...)
+
「ラベルと順序は無関係」と明示

バイアス発生率:2%

→位置バイアスの発生率を約 70% から 2% 程度まで低減


教師あり微学習の拡張実験

● 出力形式 : List形式 vs Sentence形式

学習データについて、出力形式の違いが推論精度に与える影響の検証

- ・List形式: 正しい順序のアルファベット記号のみをリスト形式で出力
- ・Sentence形式: ラベルに続けて物語全体を再構成して出力

実験1: 学習データスケールリング則 (1k → 2k → 5k)



実験2: 推論過程学習の有効性

学習データ内に明示的な「思考プロセス」を組み込むことでモデルの推論
能力に直接的に強化できるか

学習データ形式

```
{ "instruction": "[タスク指示]",  
  "input": "[5つの文セット]",  
  "output": "<think>[reasoning process]</think>  
            [answer (List 形式 or Sentence 形式)]" }
```

推論過程には、
・ GPT-5
・ Qwen3-8B
の正解に至った思考過程を抽出

表 2 思考過程の導入および Teacher モデルの違いによる性能評価 (Qwen3-8B, 1k データ, List 形式)

手法 (学習データ種別)	推論	PMR	Kendall's τ	PA
Base	ON	0.64	0.754	0.746
Standard SFT	OFF	0.58	0.848	0.782
SFT Qwen3-8B _{Think}	ON	0.52	0.588	0.628
SFT Qwen3-8B _{Think}	OFF	0.46	0.776	0.694
SFT GPT-5 _{Think}	ON	0.56	0.808	0.752
SFT GPT-5 _{Think}	OFF	0.47	0.812	0.722

- ・指標間の逆転現象と推論出力の不安定 (推論ON 推論OFF)
→推論機能ONでPMRは↑ / ケンドール順位相関は↓
- ・思考過程学習の根本的な非効率性
→複雑な思考トレースのコストがリソースを圧迫
→PMR低下を引き起こす可能性

考察・まとめ・今後の展望

- 単一タスクの小規模学習のみでは、事前学習による汎用的な推論能力の代替は困難
- 「直接回答を学習したモデル > 思考過程も学習したモデル」
小規模モデルの容量限界に起因
推論過程の再現が冗長化し、自己汚染を引き起こした可能性

- 提案モデル(List形式+学習データ 5,000件)で「PMR51%→70%」
の向上を達成
→ 今後、推論機能を活かした学習方法を模索したい
- 投票アンサンブルによる難易度ラベル
 - ・ 人手評価を導入し、評価データの妥当性の検証
 - ・ 学習データにも難易度をラベルを付与し、データの信頼性向上

参考文献

[1] Xiong, S., Payani, A., Kompella, R., & Fekri, F. (2024). Large language models can learn temporal reasoning. *arXiv preprint arXiv:2401.06853*.
[2] Rzepka, R., Dudzic, K., Abe, A., & Araki, K. (2024). *DanSto-Japanese dataset of short stories for evaluating context understanding* (pp. 32-40). JSAI Technical Report, Type 2 SIG 2023 (AGI-026).

