

計算資源制約下における言語モデルの日本語ストーリー文順序付け能力の評価

北海道大学大学院 情報科学院 情報科学専攻 メディアネットワークコース

言語メディア学研究室 横山明咲

【緒言】

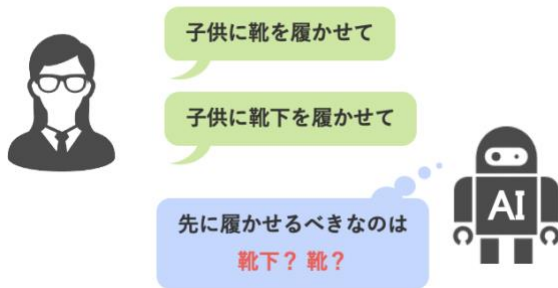
大規模言語モデル（LLM）の社会実装が進む中、特にロボット等の自律システムにおいては、文脈から出来事の順序を把握する「時間的推論」能力が不可欠である。

本研究では、高度な文脈理解を要する文順序付けにおいて、計算資源の限られた環境で動作する「小規模言語モデル」における時間的推論能力の限界の突破を検証し、GPT-4 などの高性能モデルに迫る精度を目指す。

【背景】

～文順序付け～

例）親がロボットに子供のお世話を頼んだ場合…



子供に靴を履かせる命令した後に、子供が靴下を履いていないことに気づき、ロボットなどの自律エージェントに左図の順で命令を行わせた。

人間なら「靴下→靴」の順で履かせるが、ロボットは以上のような出来事の順序を理解する「時間的推論」能力が存在するのか？

→文順序付けタスクを用いてその能力の限界を検証

～クラウド LLM と小規模サイズのローカル LLM～

クラウド LLM（大規模サイズ）	ローカル LLM（小規模サイズ）
【特徴】 常時通信環境が必要	【特徴】 通信不要（高秘匿）、運用コストが低い
【利点】 非常に高い汎用性を持つ	【課題】 大規模モデルと比較して推論性能に限度あり
【例】 ChatGPT, Gemini 等	【例】 Qwen3, Gemma 等

・理想的な AI 像：運用コストなし / 高い秘匿性 / 通信環境不要 が実現できるローカル環境で動作可能な AI

→理想的な AI エージェントの実現にはローカル環境で動く「小規模言語モデル」の精度向上が不可欠

【課題】

以下のランダムに並べた5文を正しい順に並び替えてラベルのリスト形式で出力して

- 0) 私はコップに牛乳を注いだ。
- 1) 朝ご飯はみんなで準備をする。
- 2) 私はトーストにバターを塗っていた。
- 3) 朝ご飯は家族みんなで食べる。
- 4) 親が冷蔵庫から牛乳を持ってきた。

[3, 1, 2, 4, 0]



何も対策をしていない状態で左図のようにタスクを行ったところ、精度は「約 2.57%」と実用には程遠い極めて低い精度を記録した。

GPT-4o の精度についても「約 70%」程度という汎用性の高いモデルとしては高くない精度であった。

→ ①実験環境の最適化と②モデル性能向上に着目してローカルモデルの精度向上を目指した。

【① 実験環境の最適化】

モデルが出力した回答とタスクに用いたデータについて分析を行ったところ以下を発見した。

1. 評価データの厳密化


データセット内に、複数通りの順序で解釈可能な「文脈の曖昧性」を持つデータが含まれていることを特定した。

3つの高性能 LLM による投票アンサンブルを行い、データごとに難易度のラベル付けを行うことで、「全員が正解できる一意的なデータ (Easy)」のみを厳選して評価に用い、モデルの真の文脈理解能力を測定できる環境を整えた。

表1 LLM 投票アンサンブルによるデータ分類基準		
分類	定義 (3 モデルの回答状況)	採用
Easy	全員が正解 (Correct, Correct, Correct)	○
Medium	多数決で正解 (Correct, Correct, Incorrect)	×
Ambiguous	全員または一部が同じ誤答 (別解の可能性)	×
Hard	不正解が分散	×
Very Hard	全員が異なる間違い	×

2. 回答バイアスの制御

本研究では全文生成ではなくラベルを用いたリスト形式を指定していたが、特定の順序で出力される「位置バイアス」が約 70 %発生していることを特定。プロンプトの最適化を実施した。
以下のようにプロンプトを最適化させることで位置バイアスの発生率を 70%→2%程度まで低減させることに成功した。




以上のようなデータと出力の徹底的な分析により本来のベースとなる 51%という適切な推論能力の測定に成功した。

【② モデル性能向上】

構築した評価環境のもと、モデル自体の推論能力を向上させるため、教師あり微調整 (SFT) を実施した。

- 【使用モデル】 Qwen3-8B (推論モード ON / OFF)
- 【学習データ数】 1k / 2k / 5k で調査
- 【結果・考察】 最良モデルは 70%と精度向上に成功した。


- ・提案手法を適用したモデルはベースラインを上回った
→パターンの暗記だけでなく時間経過・因果関係が学習されていることを確認
- ・ベースモデルの精度「推論モード ON > OFF」に対して、提案手法のモデルでは推論モード ON/OFF の精度の差が小さい
→ Qwen3 の推論モードの能力を活かした学習方法の可能性



【まとめ・今後の展望】

実験環境とモデルの性能のどちらの視点も踏まえた分析・提案により GPT-4o (93%) に近づく性能向上を実現することができた。

今後は、モデルの持つ推論モードの能力を活かした学習方法を考案し、複数解釈の可能な日本語ストーリー (Medium/Ambiguous etc.) に対しても対応できるモデルを構築することで、より自由度の高い言語の解釈に適応したモデルを目指す。



【活動実績】

2026 年度 人工知能学会 (第 40 回) 採択 (<https://pub.conf.it.atlas.jp/ja/event/jsai2026/presentation/2Yin-B-06>)